PB19111713钟颖康

13.15 在一年一度的体检之后,医生告诉你一些坏消息和一些好消息。坏消息是你在一种严重疾病的测试中结果呈阳性,而这个测试的准确度为99%(即当你确实患这种病时,测试结果为阳性的概率为0.99;而当你未患这种疾病时测试结果为阴性的概率也是0.99)。好消息是,这是一种罕见的病,在你这个年龄段大约10000人中才有1例。为什么"这种病很罕见"对于你而言是一个好消息?你确实患有这种病的概率是多少?

- 因为与"未患病但测试结果为阳性的概率"相比,若这种病很罕见(即患病的概率远低于此),则表示大多数阳性测试结果均为误判。
- ullet 设患病为M,检测结果阳性为N,则确实患病的概率可表示为P(M|N)

$$P(M|N) = \frac{P(M \cdot N)}{P(N)} = \frac{\frac{1}{10000} \cdot 99\%}{\frac{10000-1}{10000} \cdot 1\% + \frac{1}{10000} \cdot 99\%} \approx 0.0098$$

13.18 假设给你一只袋子,装有n个无偏差的硬币,并且告诉你其中n-1个硬币是正常的,一面是正面而另一面是反面。不过剩余1枚硬币是伪造的,它的两面都是正面。

- a. 假设你把手伸进口袋均匀随机地取出一枚硬币,把它抛出去,硬币落地后正面朝上。那么你取出伪币的(条件)概率是多少?
- b. 假设你不停地抛这枚硬币,一共抛了k次,而且看到k次正面向上。那么你取出伪币的条件概率是多少?
- c. 假设你希望通过把取出的硬币抛k次的方法来确定它是不是伪造的。如果抛k次后都是正面朝上,那么决策过程返回fake(伪造),否则返回normal(正常)。这个过程发生错误的((无条件)概率是多少?
  - **a.** 设取出伪币为R,抛一次正面朝上为S,则取出伪币的概率可表示为P(R|S)

$$P(R|S) = rac{P(R \cdot S)}{P(S)} = rac{rac{1}{n} \cdot 1}{rac{n-1}{n} \cdot rac{1}{2} + rac{1}{n} \cdot 1} = rac{2}{n+1}$$

• **b.** 设抛了k次正面朝上为T,则取出伪币的概率可表示为P(R|T)

$$P(R|T) = \frac{P(R \cdot T)}{P(T)} = \frac{\frac{1}{n} \cdot 1^k}{\frac{n-1}{n} \cdot (\frac{1}{2})^k + \frac{1}{n} \cdot 1^k} = \frac{2^k}{n - 1 + 2^k}$$

• **c.** 发生错误即取出的不是伪币且抛k次正面朝上,故发生错误的概率可表示为 $P(ar{R}\cdot T)$ 

$$P(\bar{R} \cdot T) = \frac{n-1}{n} \cdot (\frac{1}{2})^k = \frac{n-1}{n \cdot 2^k}$$

- 13.21 (改编自Pearl (1988)的著述。)假设你是雅典一次夜间出租车肇事逃逸的交通事的目击者。雅典所有的出租车都是蓝色或者绿色的。而你发誓所看见的肇事出租车是蓝色的。大量测试表明,在昏暗的灯光条件下,区分蓝色和绿色的可靠度为75%。
- a. 有可能据此计算出肇事出租车最可能是什么颜色吗? (提示:请仔细区分命题"肇事车是蓝色的"和命题 "肇事车看起来是蓝色的"。)
- b. 如果你知道雅典的出租车10辆中有9辆是绿色的呢?
  - a. 设肇事车是蓝色的为M,肇事车看起来是蓝色的为N,则肇事出租车的确是蓝色可表示为 P(M|N)

$$P(M|N) = \frac{P(M \cdot N)}{P(N)} = \frac{75\% \cdot P(M)}{25\% \cdot (1 - P(M)) + 75\% \cdot P(M)} = \frac{3 \cdot P(M)}{1 + 2 \cdot P(M)}$$

若想判断是P(M|N)较大还是 $P(\bar{M}|N)$ 较大需要知道P(M)的具体数值,即光凭现有条件不能计算最可能是什么颜色

• **b.** 根据题意, $P(M)=rac{1}{10}$ ,结合**a.**可知P(M|N)=0.25,故最可能是绿色

13.22 文本分类是基于文本内容将给定的一个文档分类成固定的几个 类中的一类。朴素贝叶斯模型经常用于这个问题。在朴素贝叶斯模型 中,查询(query)变量是这个文档的类别,而结果(effect)变量 是语言中每个单词的存在与否;假设文档中单词的出现是独立的,单 词的出现频率由文档类别决定。

- a. 给定一组已经被分类的文档, 准确解释如何构造这样的模型。
- b. 准确解释如何分类一个新文档。
- c. 题目中的条件独立性假设合理吗?请讨论。
  - a. 构造模型如下:
    - 。 该模型包含各个类别的先验概率 P(category),以及各个类别文档下各个单词出现的条件概率  $P(word_i|category)$
    - P(category = c)可以用该组已经被分类的文档中,c类文档的比例来估计
    - 。  $P(word_i = true | category = c)$ 可以用所有c类文档中单词 $word_i$ 出现的比例来估计
    - $P(word_i = true)$ 可以用所有文档中各个单词出现的比例来估计
  - **b.** 当得到一个新文档时,根据新文档中包含的词来判断文档是否包含某个词 $word_i$ ,最后来计算该文档为c类的概率 $P(category=c|\ldots,word_i=w_i,\ldots)$ ,选取最大的可能作为新文档的分类。
  - c. 不合理。因为一篇文档中很多单词都是互相联系的,一些组合大概率会同时出现。